

奇异值分解

奇异值分解是一种矩阵因子分解方法，是线性代数的内容，被引入到机器学习中。

定义与性质

定义

矩阵的奇异值分解是指，将一个非0的 $m \times n$ 的实矩阵 A ， $A \in R^{m \times n}$ ，表示为以下三个实矩阵的乘积：

$$A = U \Sigma V^T$$

其中 U 是 m 阶正交矩阵， V 是 n 阶正交矩阵， Σ 是由降序排列的非负的对角线元素组成的 $m \times n$ 矩形对角矩阵。也即：

$$\begin{aligned} UU^T &= I \\ VV^T &= I \\ \Sigma &= \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p) \\ \sigma_1 &\geq \sigma_2 \geq \dots \geq \sigma_p \geq 0 \\ p &= \min(m, n) \end{aligned}$$

奇异值分解并不要求矩阵 A 是方阵，事实上矩阵的奇异值分解可以看做是方阵对角化的推广。

奇异值分解基本定理

若 A 为一 $m \times n$ 实矩阵，则 A 的奇异值分解存在 $A = U \Sigma V^T$ ，其中 U 是 m 阶正交矩阵， V 是 n 阶正交矩阵， Σ 是由降序排列的非负的对角线元素组成的 $m \times n$ 矩形对角矩阵。

构造性证明：

1. 确定 V 和 Σ ：

$A^T A$ 是 n 阶实对称矩阵，所以存在一个 n 阶正交矩阵 V 实现 $A^T A$ 的对角化，即有 $V^T (A^T A) V = \Lambda$ 。其中 $A^T A$ 的特征值都是非负的。事实上，令 λ 是其一个特征值， x 是对应的特征向量，则

$$\|Ax\|^2 = (Ax)^T (Ax) = x^T A^T A x = \lambda x^T x = \lambda \|x\|^2$$

于是有 $\lambda = \frac{\|Ax\|^2}{\|x\|^2} > 0$ 。

假定正交矩阵 V 的列的排列使得对应的特征值形成降序排列 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ ，计算特征值的平方根 $\sigma_j = \sqrt{\lambda_j}$ 。设矩阵 A 的秩是 r ，则矩阵 $A^T A$ 的秩也是 r 。由于 $A^T A$ 是对称矩阵，它的秩等于特征值的个数。所以有 $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r > 0, \lambda_{r+1} = \lambda_{r+2} = \dots \lambda_n = 0$ ，进一步地 $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r > 0, \sigma_{r+1} = \sigma_{r+2} = \dots \sigma_n = 0$ ，那么 V 可以表示为 $V = [V_1 \ V_2]$ ，其中 $V_1 = [v_1, v_2, \dots, v_r]$ 是非0特征值对应的特征向量， $V_2 = [v_{r+1}, v_{r+2}, \dots, v_n]$ 为特征值0对应的特征向量。

这就是矩阵 A 的奇异值分解中的 n 阶正交矩阵 V 。

令

$$\Sigma_1 = \begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_r \end{bmatrix}$$

所以矩阵 A 的奇异值分解中的 $m \times n$ 矩形对角矩阵 Σ 如下:

$$\Sigma = \begin{bmatrix} \Sigma_1 & 0 \\ 0 & 0 \end{bmatrix}$$

下面退出后面要用到的一个公式。由以上知, V_2 的列向量就是 $A^T A$ 对应于特征值为0的特征向量, 因此 $A^T A v_j = 0, j = r+1, \dots, n$ 。因此有 $AV_2 = 0$, 而 $I = VV^T = [V_1 \ V_2][V_1 \ V_2]^T = V_1 V_1^T + V_2 V_2^T$, 所以得到 $A = AI = AV_1 V_1^T + AV_2 V_2^T = AV_1 V_1^T$ 。

2. 确定 U

令

$$u_j = \frac{1}{\sigma_j} A v_j, j = 1, 2, \dots, r$$

$$U_1 = [u_1, u_2 \dots, u_r]$$

有 $AV_1 = U_1 \Sigma_1$ 。

U_1 的列向量构成了一组标准的正交基, 证明如下:

$$\begin{aligned} u_i^T u_j &= \left(\frac{1}{\sigma_i} v_i^T A^T \right) \left(\frac{1}{\sigma_j} A v_j \right) \\ &= \frac{1}{\sigma_i \sigma_j} v_i^T (A^T A v_j) \\ &= \frac{\sigma_j}{\sigma_i} v_i^T v_j \\ &= \delta_{ij} \end{aligned}$$

令 $U_2 = \{u_{r+1}, u_{r+2} \dots u_m\}$ 为 $N(A^T)$ 的一组标准正交基, 且令 $U = \{U_1 \ U_2\}$

3. 证明以上的 $U \Sigma V^T = A$

奇异值分解的计算

求矩阵

$$A = \begin{bmatrix} 1 & 1 \\ 2 & 2 \\ 0 & 0 \end{bmatrix}$$

的奇异值分解。

1. 求矩阵 $A^T A$ 的特征值和特征向量。

$$A = \begin{bmatrix} 5 & 5 \\ 5 & 5 \end{bmatrix}$$

特征值 λ 和特征向量 x 满足方程

$$(A^T A - \lambda I)x = 0$$

即为齐次线性方程组

$$\begin{cases} (5 - \lambda)x_1 + 5x_2 = 0 \\ 5x_1 + (5 - \lambda)x_2 = 0 \end{cases}$$

解得到 $\lambda_1 = 10, \lambda_2 = 0$ 。分别代入原方程可得对应的单位特征向量为

$$v_1 = [\frac{1}{\sqrt{2}} \quad \frac{1}{\sqrt{2}}]^T, v_2 = [\frac{1}{\sqrt{2}} \quad -\frac{1}{\sqrt{2}}]^T。$$

2. 求正交矩阵 V 和对角矩阵 Σ 。

由上一步得到

$$V = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

$$\Sigma = \begin{bmatrix} \sqrt{10} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

注意要注意 Σ 的形状，必要时加上0行向量使其能与 U, V 进行矩阵乘法。

3. 求正交矩阵 U 。

基于矩阵 A 的正奇异值计算得到列向量 u_1 ：

$$u_1 = \frac{1}{\sigma_1} A v_1 = \frac{1}{\sqrt{10}} \begin{bmatrix} 1 & 1 \\ 2 & 2 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} \\ 0 \end{bmatrix}$$

列向量 u_2, u_3 是 A^T 的零空间 $N(A^T)$ 的一组标准正交基。即求解以下方程组

$$A^T x = \begin{bmatrix} 1 & 2 & 0 \\ 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

即是解以下方程

$$x_1 + 2x_2 = 0$$

$$x_1 + 2x_2 = 0$$

分别取 (x_2, x_3) 为 $(1, 0)$ 和 $(0, 1)$ ，得到 $N(A^T)$ 的基

$$(-2, 1, 0)^T, (0, 0, 1)^T$$

标准化之后得到

$$u_2 = (-\frac{2}{\sqrt{5}}, \frac{1}{\sqrt{5}}, 0), u_3 = (0, 0, 1)$$

正交矩阵 U 如下

$$U = \begin{bmatrix} \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} & 0 \\ \frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

4. 综上所述

$$A = U\Sigma V^T = \begin{bmatrix} \frac{1}{\sqrt{5}} & -\frac{2}{\sqrt{5}} & 0 \\ 2 & \frac{1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{5}} & \frac{1}{\sqrt{5}} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{10} & 0 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 2 & 2 \\ 0 & 0 \end{bmatrix}$$

紧奇异值分解与截断奇异值分解

给定一个 5×4 的矩阵 A 与它的完全奇异值分解：

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix} = U\Sigma V^T = \begin{bmatrix} 0 & 0 & \sqrt{0.2} & 0 & \sqrt{0.8} \\ 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & \sqrt{0.8} & 0 & \sqrt{0.2} \end{bmatrix} \begin{bmatrix} 4 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & \sqrt{5} & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix}$$

• 紧奇异值分解：

设有 $m \times n$ 实矩阵 A ，其秩为 $\text{rank}(A) = r, r \leq \min(m, n)$ ，则称 $U_r \Sigma_r V_r^T$ 为 A 的紧奇异值分解。 $A = U\Sigma V^T$

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix} = U_r \Sigma_r V_r^T = \begin{bmatrix} 0 & 0 & \sqrt{0.2} \\ 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & \sqrt{0.8} \end{bmatrix} \begin{bmatrix} 4 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & \sqrt{5} \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

• 截断奇异值分解：

设有 $m \times n$ 实矩阵 A ，其秩为 $\text{rank}(A) = r, r \leq \min(m, n), 0 < k < r$ ，则称 $U_k \Sigma_k V_k^T$ 为 A 的截断奇异值分解。 $A \approx U\Sigma V^T$

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 \end{bmatrix} \approx U_k \Sigma_k V_k^T = \begin{bmatrix} 0 & 0 \\ 1 & 0 \\ 0 & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 4 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

可以看出紧奇异值分解对应着无损压缩，截断奇异值分解对应着有损压缩。

奇异值分解与矩阵近似

弗罗贝尼乌斯范数

矩阵的弗罗贝尼乌斯范数是向量的 L_2 范数的直接推广，对应着机器学习中的平方损失函数，定义如下：

设矩阵 $A \in R^{m \times n}, A = [a_{ij}]_{m \times n}$ ，定义矩阵 A 的弗罗贝尼乌斯范数为 $\|A\|_F = \left(\sum_{i=1}^m \sum_{j=1}^n (a_{ij})^2 \right)^{\frac{1}{2}}$ 。

设矩阵 $A \in R^{m \times n}$ ，奇异值分解为 $U\Sigma V^T$ ，其中 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ ，则

$$\|A\|_F = (\sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)^{\frac{1}{2}}$$

以上定理的证明仅仅用到正交变换不改变向量的长度，所以 $\|A\|_F = \|U\Sigma V^T\|_F = \|\Sigma\|_F$ 。

矩阵的最优近似

在秩不超过 k 的 $m \times n$ 的矩阵的集合中，存在矩阵 A 的弗罗贝尼乌斯范数意义下的最优近似矩阵 X 。而 $A' = U\Sigma'V^T$ 是达到最优值的一个矩阵。

截断奇异值分解得到的矩阵的秩为 k ，通常小于原始矩阵的秩 r ，所以是由低秩矩阵实现了对原始矩阵的压缩。

矩阵的外积展开式

矩阵 A 的奇异值分解 $U\Sigma V^T$ 也可以由外积形式表示。事实上，我们可以将 A 的奇异值分解看成矩阵 $U\Sigma$ 和 V^T 的乘积，将 $U\Sigma$ 按列分块，将 V^T 按行向量分块如下：

$$U\Sigma = [\sigma_1 u_1 \quad \sigma_2 u_2 \quad \cdots \sigma_n u_n]$$

$$V^T = \begin{bmatrix} v_1^T \\ v_2^T \\ \vdots \\ v_n^T \end{bmatrix}$$

则 $A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_n u_n v_n^T = \sum_{k=1}^n \sigma_k u_k v_k^T$ 。这就是 A 的外积展开式，其中 $u_k v_k^T$ 为 $m \times n$ 矩阵，是列向量 u_k 和行向量 v_k^T 的外积：

$$u_i v_j^T = \begin{bmatrix} u_{1i} \\ u_{2i} \\ \vdots \\ u_{mi} \end{bmatrix} [v_{1j} \quad v_{2j} \cdots v_{nj}] = \begin{bmatrix} u_{1i} v_{1j} & u_{1i} v_{2j} \cdots & u_{1i} v_{nj} \\ u_{2i} v_{1j} & u_{2i} v_{2j} \cdots & u_{2i} v_{nj} \\ \vdots & \vdots & \vdots \\ u_{mi} v_{1j} & u_{mi} v_{2j} \cdots & u_{mi} v_{nj} \end{bmatrix}$$

则我们可以定义秩为 $n-1$ 的 A_{n-1} 如下：

$$A_{n-1} = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_{n-1} u_{n-1} v_{n-1}^T = \sum_{k=1}^{n-1} \sigma_k u_k v_k^T$$

类似地我们可以定义秩为 k 的 A_k 如下：

$$A_{n-1} = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_k u_k v_k^T$$

并且该矩阵就是在弗罗贝尼乌斯范数意义下的 A 的最优近似矩阵，也就是截断奇异值分解。